

Detekcija finansijskih prevara

pomoću neuronskih mreža

PROBLEM Binarna klasifikacija na neuravnoteženom dataset-u

ULAZ

Vektor obeležja transakcije (V1–V28, Amount, Time)

IZLAZ

0 — regularna / 1 — prevara



Fakultet organizacionih nauka
Laboratorija za veštačku inteligenciju

Duboko učenje i neuronske mreže
2025/26

Student:

Aleksandar Stojilković
2022/0102

Problem i cilj projekta

01

Svaka transakcija se procenjuje kao **legitimna** ili **lažna** — ručna provera je nepraktična u realnom vremenu.

02

Dataset je izrazito neuravnotežen: samo **0.17%** transakcija su prevare, što otežava klasifikaciju.

03

Cilj: automatski model koji prepoznaje prevarne transakcije uz visok Recall i zadovoljavajući Precision.

PRIMER TOKA

ULAZ: V1=-1.36, V2=0.07, ..., Amount=149.62 → neuronska mreža → **IZLAZ:** 0 — Regularna transakcija

Dataset

284.807

transakcija

31

kolona


0.17%

su prevare

Korišćene kolone

Kolona	Opis
V1 – V28	PCA transformisana obeležja (anonimizovana)
Amount	Iznos transakcije
Time	Vreme od prve transakcije
Class	0 = regularna, 1 = prevara



Raspodela klasa



Analiza i priprema podataka

- 1 Učitavanje CSV fajla (creditcard.csv)
- 2 Nema nedostajućih vrednosti među kolonama
- 3 StandardScaler na kolonama Amount i Time
- 4 Dodavanje scaled_Amount i scaled_Time
- 5 Uklanjanje originalnih Amount i Time kolona
- 6 Stratifikovana podela 80% / 20% (train/test)

Raspodela iznosa i vremena transakcija



Korišćeni modeli

MODEL 1

Osnovni model

Feedforward neuronska mreža sa ručno odabranim hiperparametrima.

Arhitektura:

Dense(64) → Dropout(0.3) →
Dense(32) → Dropout(0.3) →
Sigmoid

MODEL 2

Class Weights

Ista arhitektura, ali sa `compute_class_weight('balanced')` tokom treninga.

Arhitektura:

Identična arhitektura +
`class_weight` parametar

MODEL 3

Keras Tuner

RandomSearch pretraga optimalnih hiperparametara — 10 pokušaja.

Arhitektura:

Dense(128) → Dropout(0.3) →
Dense(64) → Dropout(0.2) →
Sigmoid

Treniranje i hiperparametarska optimizacija

KONFIGURACIJA TRENINGA

Optimizer	Adam
Loss	binary_crossentropy
Batch size	256
Epochs	20 (uz EarlyStopping)
Monitor	val_loss, patience=3

KERAS TUNER — OPTIMALNI HIPERPARAMETRI

Hiperparametar	Pronađena vrednost
Neuroni u 1. sloju	128
Dropout 1	0.3
Neuroni u 2. sloju	64
Dropout 2	0.2
Learning rate	0.0001

ANALIZA OSETLJIVOSTI

Pored osnovnog modela, analiziran je i uticaj class weights pristupa, kao i različitih kombinacija hiperparametara dobijenih pomoću Keras Tuner RandomSearch algoritma (10 pokušaja, cilj: minimizacija val_loss). Rezultati su pokazali da povećanje složenosti modela ne dovodi automatski do boljih performansi.

Poređenje performansi modela

Poređenje performansi modela (%)

Model 1 (Osnovni) Model 2 (Class Weights) Model 3 (Keras Tuner)

Metrika

Accuracy	99.94%	97.91%	99.94%
Precision	81.63%	7.08%	81.00%
Recall	81.63%	91.84%	82.65%
F1-score	81.63%	13.14%	81.82%
ROC-AUC	98.07%	98.09%	98.05%

M1

Savršeno balansiran Precision/Recall (81.63%). Solidan polazni model.

M2

Recall 91.84%, ali Precision samo 7.08% — veliki broj lažno pozitivnih. Neupotrebljiv.

M3

Recall 82.65% uz Precision 81.00% — najboljim F1-score (81.82%). Konačni model.

Glavna metrika: F1-score

Dataset nije balansiran pa accuracy nije dovoljna metrika. F1-score daje ravnopravniji uvid u kvalitet klasifikacije prevara i regularnih transakcija.

Evaluacija najboljeg modela

NAJBOLJI MODEL

Model 3 (Keras Tuner)

99.94%

ACCURACY

81.00%

PRECISION

82.65%

RECALL


81.82%

F1-SCORE

ROC-AUC: 98.05% — sve tri krive praktično identične


TN=56.845 FP=19 FN=17 TP=81

Konfuziona matrica



ROC krive i zaključna razmatranja

Poređenje ROC krivih



ROC krive

Sve tri krive su gotovo identične ($AUC \approx 0.98$). Razlike u Precision/Recall posledica su položaja odlučne granice, ne kvaliteta naučenog.

Model 2

Class weights pomeraju odlučnu granicu — visok Recall ali katastrofalan Precision (7.08%). Neupotrebljiv u praksi.

Model 3

Keras Tuner pronašao optimum: Dense(128)→Dense(64), lr=0.0001 — sistematska pretraga donosi merljivo poboljšanje.

Zaključak & pitanja

- 1 Model 3 (Keras Tuner) proglašen je najboljim: F1=81.82%, Recall=82.65%
- 2 TF/Keras feedforward mreže uspešno rešavaju problem i bez SMOTE-a
- 3 ROC-AUC $\approx$ 0.98 za sve modele — razlike nastaju iz odlučne granice
- 4 Moguća unapređenja: SMOTE, autoenkoder, XGBoost, Bayesian optimizacija

F1 = 81.82%

Konačni model · Model 3

Hvala na pažnji.

PITANJA & DISKUSIJA



Fakultet organizacionih nauka
Laboratorija za veštačku inteligenciju
Duboko učenje i neuronske mreže
2025/26

Student:
Aleksandar Stojilković
2022/0102