

Detekcija finansijskih prevara pomoću neuronskih mreža

Predmet: Duboko učenje i neuronske mreže

1. Cilj projekta

Glavni cilj ovog projekta jeste razvoj sveobuhvatnog i pouzdanog sistema za automatsku detekciju prevarnih transakcija unutar sistema plaćanja kreditnim karticama, primenom savremenih arhitektura veštačkih neuronskih mreža.

Na osnovu anonimizovanih numeričkih karakteristika svake pojedinačne transakcije, razvijeni model vrši klasifikaciju na regularne ili potencijalno prevarne aktivnosti. Problem se rešava kao zadatak binarne klasifikacije, čime se finansijskim institucijama omogućava automatsko prepoznavanje sumnjivih obrazaca ponašanja u realnom vremenu.



2. Skup podataka (Dataset)

Za razvoj i validaciju modela korišćen je Kaggle Credit Card Fraud Detection Dataset koji sadrži realne transakcije evropskih korisnika. Skup podataka karakteriše ekstremna klasna neuravnoteženost (class imbalance):

- Struktura skupa:** Ukupno 284.807 transakcija raspoređenih u 31 kolonu. Registrovan je svega 492 prevarni unos (tek 0.172% od ukupnog skupa).
- V1 – V28:** Numerička obeležja dobijena transformacijom metodom analize glavnih komponenti (PCA) radi zaštite privatnosti.
- Time i Amount:** Vremenski razmak u sekundama od prve transakcije i finansijski iznos transakcije.
- Class (Target):** Ciljna binarna promenljiva gde vrednost 0 označava regularnu, a vrednost 1 prevarnu transakciju.

3. Priprema podataka i preprocesiranje

Kako bi se osigurala brza konvergencija neuronskih mreža, implementiran je sledeći strukturiran pipeline pripreme podataka:

- Učitavanje i analiza strukture:** Pregled tipova podataka i provera koji potvrđuje odsustvo nedostajućih (null) vrednosti.
- Feature Scaling:** Kolone Amount i Time su standardizovane pomoću StandardScaler-a kako bi se prebacile na istu skalu sa PCA atributima. Formirane su kolone scaled_Amount i scaled_Time, dok su originalne uklonjene.

- **Stratifikovana podela:** Podaci su podeljeni na trening i test skup primenom stratifikovanog razdvajanja (Stratified Split), čime je garantovano da u oba skupa ostane identičan procenat (0.172%) prevarnih transakcija.

4. Arhitekture implementiranih modela

U okviru istraživanja razvijena su i upoređena tri specifična pristupa:

Model 1: Osnovni Feedforward Neuronski Model (Baseline)

- Arhitektura: Ulaz (30 obeležja) →Dense(64, ReLU) →Dropout(0.3) →Dense(32, ReLU) →Dropout(0.3) →Dense(1, Sigmoid).
- Uloga: Služi kao osnovni model za poređenje performansi bez dodatnog balansiranja klasa.

Model 2: Neuronska mreža sa težinama klasa (Class Weights)

Koristi identičnu topologiju kao Model 1, ali uvodi ponderisanje funkcije gubitka (Class Weights) kako bi se greške nad manjinskom klasom (1) strože kažnjavale tokom treniranja, čime se direktno rešava problem neuravnoteženosti podataka.

Model 3: Optimizovan model pomoću Keras Tuner-a

Predstavlja konačni i najbolji model dobijen primenom Keras Tuner RandomSearch algoritma kroz 10 iteracija optimizacije prostora hiperparametara. Automatizovano su varirani: broj neurona u skrivenim slojevima, stopa dropout regularizacije i stopa učenja (learning rate).

5. Proces treninga i konfiguracija

Svi modeli su trenirani u TensorFlow/Keras okruženju sa sledećim podešavanjima optimizovanim za stabilnost i konvergenciju:

Parametar treninga	Vrednost / Opis i uloga u modelu
Optimizator	Adam (Adaptive Moment Estimation) – pruža dinamičku i adaptivnu stopu učenja.
Funkcija greške	Binary Crossentropy – optimizovano za probleme binarne klasifikacije.
Veličina paketa	Batch size 256 – optimalan balans između brzine proračuna i stabilnosti gradijenta.
Trajanje treninga	Maksimalno 20 epoha uz kontinuirano praćenje validacionog skupa.
Rana obustava	EarlyStopping callback – automatski prekida trening ako validaciona greška stagnira.

6. Metrike evaluacije i validacija

Zbog ekstremnog debalansa klasa, metrika Accuracy nije dovoljna. Evaluacija modela sprovedena je upotrebom skupa komplementarnih metrika koje detaljno prate ponašanje na test podacima:

- **Precision & Recall:** Preciznost minimizuje lažne uzbune (FP), dok odziv (Recall) garantuje maksimalnu detekciju stvarnih prevara (minimizuje FN).
- **F1-score & ROC-AUC:** Harmonijska sredina daje uvid u balans modela, dok površina ispod ROC krive meri sposobnost separacije klasa.
- **Konfuzionna matrica:** Eksplicitno prikazuje tačne (TP, TN) i pogrešne (FP, FN) odluke modela.

7. Artefakti i očekivani ishodi projekta

Kas krajnji rezultat uspešno završenog projekta generisani su i sačuvani sledeći produkcionni fajlovi:

- **credit_card_fraud_model.keras:** Potpuno sačuvana struktura i optimalne težine konačnog Modela 3 za brzu klasifikaciju novih transakcija u realnom vremenu.
- **scaler.pkl:** Serijalizovani objekat StandardScaler-a koji obezbeđuje konzistentnu transformaciju dolaznih podataka.

Kreirani sistem uspešno automatizuje kompletan pipeline – od sirovog finansijskog unosa do precizne odluke o legitimnosti transakcije, pružajući maksimalnu sigurnost uz minimalne lažne alarme.